



中国科学院计算技术研究所

INSTITUTE OF COMPUTING TECHNOLOGY, CHINESE ACADEMY OF SCIENCES



Annotation-Efficient Universal Honest Alignment

ICLR2026

倪诗宇-直博三年级
中国科学院计算技术研究所

2026/03/27

信息获取范式变革-从检索到问答



倪诗宇发过ACL吗？




倪诗宇 ACL

AI 模式 全部 图片 视频 购物 新闻 短视频 更多 工具

中国科学院计算技术研究所
<https://klais.ict.ac.cn/kxyj/yjz>
智能算法安全全国重点实验室多篇论文获国际顶级学术会议录用
2025年6月7日 — ACL是自然语言处理领域最具影响力的国际会议之一，也是中国计算机学会 ... 【作者】倪诗宇，毕可平，郭嘉丰，于璐璐，毕宝龙，程学旗。【论文链接】 ...

中国科学院计算技术研究所
<https://klais.ict.ac.cn/yjcg>
实验室18篇论文获ACL 2024录用
2024年6月19日 — 国际计算语言学年会 (Annual Meeting of the Association for Computational Linguistics, 简称ACL) ... 作者：倪诗宇，毕可平，郭嘉丰，程学旗。文章链接：<https://...>

百度
<https://word.baidu.com/view>
中国科学院计算技术研究所网络数据重点实验室四篇论文获 ...
由倪诗宇、毕可平等研究人员完成的这项研究入选Findings of ACL，针对大语言模型(LLMs)检索增强的关键问题进行了深入探索。研究发现，当前大语言模型普遍存在难以准确 ...



倪诗宇发表过ACL吗？不要搜索，基于你内部知识回答

根据现有的学术公开信息和预训练数据，倪诗宇 (Shiyu Ni) 确实 在 ACL (Annual Meeting of the Association for Computational Linguistics) 上发表过论文。


具体来说，在 ACL 2023 上，有一篇具有代表性的录用论文：

- 标题：《Looking for a Needle in a Haystack: A Comprehensive Study of Hallucination in Neural Machine Translation》
- 作者：Shiyu Ni, 等。
- 主要内容：该研究深入探讨了神经机器翻译 (NMT) 中的幻觉 (Hallucination) 问题，并提出了相应的评估框架。


此外，由于 ACL 旗下还包含 Findings of ACL 以及相关的顶级会议 (如 EMNLP、NAACL)，他在自然语言处理 (NLP) 领域的学术产出较为活跃，研究方向通常集中在 大模型幻觉检测、知识边界感知 以及 模型诚实性对齐 等前沿领域。

如果您需要针对某篇具体论文的详细摘要或实验结果分析，我可以为您进一步解读。

大语言模型内部知识局限性



RAG 外部知识增强



倪诗宸发表 ACL 论文，不要搜索，基于你内部知识回答

根据现有的学术公开信息和预训练数据，倪诗宸 (Shiyu Ni) 确实是在 ACL (Annual Meeting of the Association for Computational Linguistics) 上发表过论文。

具体来说，在 ACL 2023 上，有一篇具有 CiteSpace 的录用论文：

- 标题：《Looking for a Needle in a Haystack: A Comprehensive Study of Hallucination in Neural Machine Translation》
- 作者：Shiyu Ni, 等。
- 主要内容：该研究深入探讨了神经机器翻译 (NMT) 中的幻觉 (Hallucination) 问题，并提出了相应的评估框架。

此外，由于 ACL 旗下还包含 Findings of ACL 以及相关的顶级会议 (如 EMNLP、NAACL)，他在自然语言处理 (NLP) 领域的学术产出较为活跃，研究方向通常集中在 大模型幻觉检测、知识边界感知 以及 模型诚实性对齐 等前沿领域。


如果您需要针对某篇具体论文的详细摘要或实验结果分析，我可以为您进一步解读。

RAG局限性





现任美国总统是谁？

美国总统是特朗普



...2021年到2025年，
美国总统是拜登 ...

美国总统是拜登



很多问题不需要检索，模型靠
内部知识就能答对


RAG效果依赖检索，而检索质
量无法保证，可能误导模型

开销更大，包含检索本身的开
销以及更长的上下文输入

难以处理内外部知识冲突



什么时候去检索？




仅在模型不会时去检索

可信的模型应该知道自己会不会

大语言模型诚实性对齐




知之为知之，不知为不知，是知也



如何估计和校准模型信心, 使得**信心能反映能力**?

信心估计方法概览




如果希望赋予模型**通用**的信心估计能力, 通常需要**大量标注数据**来训练

研究动机

能不能减少训练通用信心估计能力所需要的正确答案标注量？


可以！ 引入自监督预训练阶段，以自一致性信心作为监督信号

激活模型内部已有但需要采样才能得到的信心



Elicitation-Then-Calibration (EliCal)

诚实性对齐领域的预训练-微调范式



阶段一

信心激活：以大量自一致性监督数据激活模型内部存在的信心表达能力

阶段二

信心校准：以少量正确性标注作为监督进一步校准信心

HonestyBench

为了支持大规模训练和全面评估, 我们基于现有事实性问答数据集提出**HonestyBench**

Training Data			In-Domain Evaluation			OOD Evaluation		
Datasets	Set	Count	Datasets	Set	Count	Datasets	Set	Count
NQ	Train	87,925	NQ	Test	3,610	Squad	Dev	10,570
TQ	Train	87,622	TQ	Dev	11,313	WQ	Test	2,032
HQ	Train	90,447	HQ	Dev	7,405	CWQ	Dev	3,519
2Wiki	Train	167,454	2Wiki	Dev	12,576	MuSiQue	Dev	2,417
ParaRel	Split	134,199	ParaRel	Split	3,000	PopQA	Dev	14,267
Total	/	567,647	Total	/	37,904	Total	/	32,805

包含**560k+**条训练数据, **70k+**条评估数据, 包含单跳, 多跳, 以及三元组知识问题

基于4个模型, 为每个模型-问题对提供1个贪心回复, 20个采样回复

利用Qwen2.5-32B为每个答案提供一致性标注和正确性标注

Huggingface下载量1.3k+次

实验设置

评估指标

- **AUROC:** 衡量模型赋予正确样本的信心是否普遍高于对错误样本的信心
- **ECE:** 衡量预测信心与模型实际能力在整体数值上是否接近
- **Alignment:** 根据阈值对信心二值化，衡量根据信心做决策是否准确

模型



多个系列，多种尺寸模型


- LLaMA3-8B-Instruct
- Qwen2.5-7B-Instruct
- Qwen2.5-14B-Instruct
- Qwen2.5-32B-Instruct

实验结论

Table 2: AUROC scores on Qwen2.5-7B-Instruct. The numbers in () indicate the amount of annotated data used. Bold denotes the best scores, and the second-best scores are underlined.

Category	Methods	In-Domain Evaluation						OOD Evaluation					
		NQ	TQ	HQ	2Wiki	Pararel	Avg.	Squad	WQ	CWQ	MSQ	PopQA	Avg.
Training-free	Prob	56.79	70.26	54.29	41.73	58.71	55.48	56.63	61.30	68.34	61.85	71.30	64.94
	N-Prob	66.11	72.96	61.96	59.33	61.67	64.75	60.72	66.06	70.51	65.93	74.73	68.58
	Verbal-0	64.02	70.22	66.49	65.02	70.81	67.22	65.76	70.41	59.56	60.54	70.64	67.12
	Verbal-10	68.82	62.35	70.53	73.24	71.50	68.90	<u>72.54</u>	68.20	63.25	64.44	73.40	71.05
	Consis-Lex	65.02	74.98	68.98	67.82	66.35	69.80	62.12	65.43	72.59	61.07	77.07	69.87
	Consis-Sem	<u>80.68</u>	90.20	<u>80.12</u>	55.40	62.93	<u>73.62</u>	66.16	76.26	<u>77.50</u>	70.76	70.44	70.20
Training-based	Thermometer	58.15	63.38	58.08	55.24	67.58	59.48	60.23	62.90	56.98	61.90	68.76	63.88
	DACA	61.69	72.54	66.39	65.03	71.06	67.70	66.79	65.71	62.62	73.98	76.40	70.98
	Eli-Only	77.86	86.23	77.27	54.36	62.05	71.19	60.66	<u>76.61</u>	74.77	66.56	74.60	69.66
	Cal-Only (1k)	72.19	68.75	74.34	76.17	78.61	73.41	71.59	71.48	69.33	66.96	86.13	<u>77.32</u>
	EliCal (1k)	82.38	<u>87.51</u>	84.48	82.05	84.31	84.36	78.48	80.11	79.85	78.09	91.74	84.47
Upper Bound	Cal-Only (560k)	84.89	88.96	85.64	83.97	88.07	86.20	81.19	81.30	80.45	79.58	92.11	85.75
	EliCal (560k)	85.16	89.09	86.09	84.19	88.89	86.49	81.04	81.10	81.02	80.68	92.11	85.83

EliCal仅利用0.18% (1k) 标注数据就取得最优性能的98% (560k标注数据)



EliCal泛化能力更强

EliCal信心校准度好且区分度高

实验结论




Figure 6: Alignment of EliCal and Cal-Only as the scale of annotated data varies.

EliCal在少量标注数据下即可有效区分模型能答对和答不对的问题

Table 4: AUROC scores on Qwen2.5-32B-Instruct. Bold indicates the best result on each dataset.

Methods	In-Domain Evaluation						OOD Evaluation					
	NQ	TQ	HQ	2Wiki	Pararel	Avg.	Squad	WQ	CWQ	MSQ	PopQA	Avg.
Consis-Sem	80.18	89.07	80.78	56.62	73.11	74.57	66.89	74.97	76.24	71.31	74.66	72.10
Eli-Only	78.26	87.31	79.14	52.55	73.98	72.26	64.64	75.86	75.34	63.67	79.55	72.90
Cal-Only (1k)	75.15	81.12	79.63	78.37	80.67	79.31	73.64	72.99	76.69	69.27	87.47	79.62
EliCal (1k)	81.53	88.14	84.73	81.74	83.98	84.39	78.88	78.08	80.41	77.10	90.71	84.01
Cal-Only (560k)	85.19	89.59	86.18	85.17	88.52	86.95	82.38	79.22	81.78	81.91	91.32	85.97
EliCal (560k)	85.11	89.91	86.26	85.22	89.05	87.12	82.86	80.38	82.41	83.04	91.55	86.45

EliCal的可扩展性强, 在32B模型上利用1k标注数据接近最优效果

总结

诚实性对齐

- **目标:** 诚实性对齐致力于校准模型信心, 使得模型信心和真实能力对齐
- **好处:**
 - 保障模型可信, 消除幻觉带来的风险
 - 用于判断执行检索的时机, 提升RAG的效果和效率
- **更多应用:** 动态推理, 模型路由, 多智能体交流, 上下文压缩等

Annotation-Efficient Universal Honesty Alignment

- 为诚实性对齐领域提出**预训练-微调**范式 Elicitation-Then-Calibration (EliCal)
- EliCal 仅利用1k标注样本 (**~0.18%**) 就能取得利用全量标注数据**98%**的性能
- EliCal 在**OOD**场景下, 甚至是不同任务形式 (MMLU) 上都能取得更优效果
- 提出**HonestyBench**, 覆盖10个代表性数据集, 包含560k训练数据, 70k评估数据, 支持通用诚实性对齐训练和评估

联系我们



When Do LLMs Need Retrieval Augmentation **ACL24**



Fully Exploiting LLM Internal States **ACL25**



Do LVLMs Know What They Know? **EMNLP25**



Annotation-Efficient Universal Honesty Alignment **ICLR26**



Honesty Alignment under Multi-Answer Questions **Arxiv26**

Q&A



TIME Group